个人信息

- 高乾/男/1993 | 手机：18910905396，邮箱：1210639198@qq.com
- Github：https://github.com/qianandgrace

- 求职意向：AI应用开发工程师 | 期望城市：北京

教育经历

学校	学历，专业	时间
伊利诺伊理工大学	硕士，计算机科学	09/2020 - 01/2024
中南大学	学士，车辆工程	09/2010 - 06/2014

技能清单

医疗健康 LLM 应用（安全与可控）

- 熟悉医疗咨询类对话系统的安全边界设计：风险分级、红旗症状提示、就医分流（居家/门诊/急诊）、免责声明与“不可替代医生诊断”提示
- 熟悉可追溯输出：检索命中文档以 **citation/source** 形式注入上下文，回答末尾强制引用出处，便于审计与降低幻觉风险
- 熟悉结构化信息抽取与表单化管理：从对话中抽取过敏史/慢病/用药/体征等，沉淀为可编辑健康档案

RAG 工程化 / 知识库

- 熟悉 RAG 全流程：文档清洗、分块、Embedding、向量检索、重排（rerank）、命中片段拼接与引用回传
- 熟悉向量数据库 **Milvus / Chroma**：向量入库、元数据过滤（成员级隔离）、召回参数调优（topK/阈值）
- 熟悉中文 Embedding 模型（如 **BAAI/bge-large-zh-v1.5**），理解相似度度量与召回效果评估

Agent 工作流编排

- 熟悉 **LangGraph** 节点化编排：信息抽取 → 缺失追问 → 个人史检索 → 知识库检索 → 风险分级 → 回复生成 → 记忆写入
- 熟悉多角色/多成员记忆隔离：按 `family_id/user_id/thread_id` 管理会话与长期记忆，避免信息串用

模型微调 / 部署

- 熟练 **LoRA / QLoRA** 指令微调（单轮/多轮），能完成数据构造、训练配置、人工评估与早停
- 熟悉 **LLaMA-Factory / Xtuner** 微调训练与推理验证
- 熟悉本地私有化部署：**vLLM / LMDeploy / Ollama**，可进行基础性能调优与服务化封装

后端与工程化

- 熟练 **FastAPI** 构建推理/检索服务接口；熟悉 **PostgreSQL** 存储结构化档案与审计字段
- 熟悉日志与异常处理、配置化、接口文档（OpenAPI/Swagger），支持 Demo 到服务化落地

工作经历

华为（2023 年 2 月 ~ 2025 年 7 月） AI算法开发工程师

1. 参与 **WiFi质差识别项目**，主导算法开发，项目在浙江局点成功商用，准确率与召回率均达到 90%
2. 参与 **光纤传感周界安防项目**，负责误报漏报数据分析并主导三级检测模型与后处理算法开发，项目在国内外多个局点成功商用

北京外企德科（2021 年 9 月 ~ 2023 年 12 月） AI算法开发工程师

1. 参与 **智能光交箱项目**，负责项目开发进度管理、端口检测模型训练与部署
2. 项目在云南局点商用，运维效率显著提升，巡检时间由 3 小时降低至 10 分钟

康明斯排放处理系统（中国）有限公司（2018年 3 月 ~ 2020 年 6 月） 系统工程师

1. 负责柴油汽车后处理系统开发

北汽福田汽车股份有限公司（2014年 7 月 ~ 2018 年 3 月） 动力系统工程师

1. 负责商用车柴油机后处理系统开发

项目经历

光交箱图像识别项目:算法开发工程师

项目背景

光交箱是通信网络中的重要哑资源，需要对内部端口占用状态进行持续监控。但由于端口排列密集、内部光纤布线复杂且存在遮挡，传统人工巡检效率低、统计误差大。

本项目通过移动端采集图像，并结合目标检测与OCR识别技术，实现光交箱端口状态的自动识别与数字化管理，从而提升巡检效率并降低人工成本。

技术方案

- **数据预处理与增强**：采集多场景光交箱图像数据，覆盖不同光照、拍摄角度及遮挡情况，采用 **亮度调整、对比度增强、噪声扰动、等数据增强方法** 扩充训练样本
- **算法方案设计**：对比多种目标检测模型，在检测速度与精度之间进行权衡,最终选型 **YOLOv5s** 作为核心检测模型，实现光交箱端口类型及占用状态检测
- **信息识别与结构化**：引入 **OCR识别算法**，识别光交箱行列标签信息，实现端口精确定位，设计 **二维码把柄标识方案**，通过二维码信息保存对应端口的匹配信息

技术亮点

- **AI + 传统识别算法结合**：融合目标检测、OCR与二维码识别，实现光交箱端口的多维信息识别
- **面向小目标密集场景优化**：针对端口密集排列问题，对YOLO模型进行参数调优，提高检测稳定性

- **移动端实时识别**：基于 **NCNN 推理框架** 实现模型移动端部署，支持现场实时巡检
- **软硬件协同方案**：通过二维码把柄等低成本硬件改造，提高识别准确率与系统可靠性

项目成果

- 实现光交箱端口状态自动识别，将巡检时间从 **3h 降至 10min（效率提升约18×）**，端口识别准确率达到 **99%**，显著降低人工巡检中的误判与漏检问题，系统已在 **广东移动与云南移动完成商用部署**，实现光交箱资源的数字化管理

技术栈

Python / YOLOv5 / NCNN / OpenCV / OCR / Android Studio

光纤传感周界安防项目:算法工程师/现网问题接口

项目背景

铁路、机场等大型周界区域的入侵事件频发，对安全运营及人员财产安全带来较大风险。由于周界环境复杂，植被、动物、车辆及风雨雪等环境因素容易产生大量干扰信号，对周界防护系统的可靠性与稳定性提出较高要求。

本项目基于 振动光缆传感技术，通过对光纤振动信号进行分析，实现对人员越界入侵行为的检测，并结合AI算法与视频监控系统，提高周界安防系统的检测准确率与环境适应能力。

技术方案

- **数据采集与预处理**：采集多种环境干扰场景数据，包括 **动物活动、植被扰动、风雨天气、车辆震动等背景数据，**采集不同体重人群、不同越界动作的 **入侵行为数据**。结合现场摄像头视频，对误报事件进行回溯定位，构建 **带有误报原因标签的干扰数据集**
- **算法方案设计**：构建 **“粗筛 + 精筛” 的多级检测架构**：轻量模型进行快速初筛，过滤大量背景干扰 + 深度模型进行精细识别，提高入侵检测准确率，利用**局部频域强度特征** 与 **全局短时方差特征**通过 **CNN网络进行特征融合**，构建三级检测模型
- **算法鲁棒性**：针对不同部署环境（如土质结构、围栏刚度等差异），引入 **物理特征模型进行围栏特性评估**，根据围栏评估结果实现 **灵敏度自适应调节与模型策略选择**，提升系统在不同局点的适应能力
- **光视联动**：基于误报类型数据训练 **后置分类模型**，并结合摄像头信息实现 **光视联动筛选真实入侵事件**
- **运维效率提升**：设计 **日志分析工具**，快速定位问题发生在多级检测模型中的具体环节。对关键特征进行可视化展示，帮助运维人员快速分析误报原因。结合前后端界面，实现 **灵敏度快速调节与逃生通道配置**，提高系统运维效率并降低AI算法不确定性带来的风险

技术亮点

- AI + 物理模型融合：**结合CNN深度学习模型与围栏物理特征模型，实现环境自适应检测**
- **多级检测架构**：通过“轻量粗筛 + 深度精筛”的检测策略，提高检测效率并降低误报率
- 光视联动安防方案：**融合光纤振动信号与摄像头检测结果，实现多模态入侵检测**
- **工程化运维工具设计**：通过日志分析与特征可视化工具，提高系统问题定位效率

项目成果

- 在 **浦东、合肥、郑州及墨西哥** 多个局点完成商用，动物干扰误报 ≤ **0.5 次/km/d**，飞机尾流误报 ≤ **0.3 次/km/d**
- 标准入侵检测 **无漏报**

技术栈

Python / CNN / 信号处理

汽车诊断助手:算法工程师 / LLM应用方向

项目背景

随着汽车电子化与智能化发展，车辆维修诊断面临信息分散、故障类型复杂的问题。传统诊断依赖技术人员查阅维修手册、OBD故障码说明及历史维修案例，效率低且易出错。本项目基于 **大语言模型（LLM）+ RAG技术**，构建 **汽车故障智能诊断助手**，实现对故障码、维修案例及维修手册的整合检索，提供自动化故障分析、检查建议及维修方案，提升维修效率并降低学习成本。

技术方案

- **数据采集与预处理**：参考开源仓库（obd-trouble-codes），包含故障码、描述、症状、可能原因、解决方案，申城obd_code 数据。收集100条网上案例，利用大模型扩展至300条，形成多样化维修经验数据。基于故障知识库，进行语义改写与多样化生成，构建1000+高质量指令数据（单轮+多轮），用于大模型微调。
- **模型选型与微调**：通过 Llama_factory 评测结果对比 Qwen 系列模型，最终选择 **Qwen2.5-3B-Instruct**，使用 **QLoRA** 降低显存占用，实现高效训练,支持单轮 + 多轮指令微调,训练中结合人工主观评估，动态早停

RAG检索与高级能力：

- **分路召回**：故障码直接查询，维修案例单独召回，避免结构化知识覆盖问题
- **Prompt Rewrite**：对用户查询进行规范化处理
- **Rerank**：基于 embedding 相似度重排序，提高检索精度
- **输出**：生成 JSON 结构化结果 + 来源编号（可前端展示点击跳转）

技术亮点

- **分路 RAG + Prompt Rewrite + Rerank**：多路召回与排序机制确保结构知识与案例知识兼顾
- **结构化输出**：JSON + 来源编号，方便前端点击查看来源，提高可解释性
- **低成本高效微调**：QLoRA 降低显存消耗，训练快速
- **工程化落地能力**：从数据 → 索引构建 → 微调 → RAG检索 → API + 前端展示闭环

项目成果

- 实现**车辆故障自动诊断与维修建议生成**，显著提升维修效率
- 支持 **多来源引用显示**，可在前端点击查看具体来源
- 整体 RAG 流程可扩展至其他车辆类型与维修知识库
- 完成从数据采集 → 微调 → RAG检索 → API + Gradio前端的全流程部署

技术栈

Python / PyTorch / LlamaIndex / Chroma / QLoRA / VLLM / FastAPI / Gradio / RAG / NLP

家庭健康助手 Agent（Agentic RAG + 长期记忆）:算法工程师 / LLM应用方向

项目背景

面向家庭健康管理场景，用户希望系统可长期维护家庭成员健康档案（过敏史、慢病、用药、家族史、饮食作息等），并结合中西医指南、常见疾病科普与小儿用药/安全知识，在日常咨询中输出可执行的导诊建议与风险提示。传统对话系统缺乏“多成员隔离记忆 + 个体化约束 + 可追溯依据”，难以在真实家庭场景稳定落地。

技术方案 / 工作内容

- **Agentic RAG 工作流（LangGraph 编排）**：搭建“Agent → Tools 调用 → 文档评分（grade）→ 生成/改写（generate/rewrite）”图结构流程，实现可控检索与回答闭环。
- 三类检索工具路由（症状分流 / 科普 / 风险直达）：定义并实现 3 个 Retriever Tool，由 LLM 根据意图与内容自动选择：包括**红旗库检索**，命中高危症状直接触发就医提示与风险告警；**分诊/科室检索（triage）**：用户问“去哪个科室/要不要去医院”等场景，结合严重等级、年龄等规则给出分流建议；**知识库检索（knowledge）**：用于疾病科普、护理建议等非紧急问题的依据检索。
- 中文向量检索与知识库建设：选型bge-base-zh-v1.5作为 embedding 模型；构建多来源中文医疗知识库并向量化，包括卫健委指南（MinerU 解析清洗为 Markdown，去除英文内容以适配中文场景）,丁香医生常见疾病讲解,爬虫整理 **30 个科室、197 个常见疾病**条目
- **红旗/分诊数据资产沉淀**：整理 **50 种高危红旗症状库** 与常见症状分诊规则库（按严重等级、年龄等维度），用于快速风险识别与导诊分流。
- **长期记忆（用户健康信息召回）**：通过特定关键词（如“记录”）触发健康信息写入；以 `user_id` 为唯一标识检索历史信息，在回答中优先结合用户既往史/过敏史等做个体化判断（对应界面图示中的“粘贴档案→对话触发记忆→后续问诊可用”）。
- **工程部署与产品化**：后端使用 **FastAPI**，前端使用 **Gradio**；支持新建/历史会话与持续对话体验，形成“对话—记忆—再利用”的闭环。

技术亮点

- **可控的 Agentic RAG**：LangGraph 图编排 + 文档评分节点，降低幻觉并提升回答一致性。
- **意图路由 + 风险优先**：红旗库命中即强制风险提示；分诊与科普走不同检索链路，提升准确性与可执行性。
- **中文场景优化**：bge-base-zh-v1.5 + 中文清洗后的指南/科普数据，显著提升中文召回质量。
- **可用的长期记忆机制**：按 user_id 隔离记忆，通过对话触发写入并在后续咨询中稳定召回，增强个体化导诊能力

项目成果

- 在家庭健康咨询中实现“**红旗识别→分诊分流→知识科普**”三类链路自动路由，输出更可执行的下一步行动建议。
- 支持用户通过对话触发健康档案记录，并在后续问诊中基于既往史/过敏史等信息提供更个体化的风险提示与建议。

技术栈

Python / LangGraph / Agentic RAG / bge / Chroma/ FastAPI / Gradio / Web Crawler / MinerU

个人评价

聚焦大模型应用开发，擅长用“结构化健康档案 + RAG 可追溯引用 + 工作流编排”构建安全、可控、可审计的对话系统。能够在 LangGraph 中实现信息抽取、缺失追问、个人史约束、知识库检索与风险分级的闭环，实现成员级记忆隔离与长期可维护档案。具备本地私有化部署与服务化落地能力，期望在北京从事LLM 应用与 Agent 系统开发工作。

感谢您花时间阅读我的简历，期待能与您共事！